

대화형 질의 응답을 위한 메모리 기반 스토리 학습

전재현*, 김은솔**, 장병탁**

*서울대학교 뇌과학전공, **서울대학교 컴퓨터공학전공

jhjun@bi.snu.ac.kr, eskim@bi.snu.ac.kr, btzhang@bi.snu.ac.kr

Memory-based Story Learning for Conversational Question and Answering

Jaehyun Jun*, Eun-Sol Kim**, Byoung-Tak Zhang**

*Interdisciplinary Program in Neuroscience, Seoul National University

**Department of Computer Science and Engineering, Seoul National University

요 약

본 논문에서는 스토리를 기반으로 대화형 질의 응답(Question and Answering, QA)을 할 수 있는 기계학습 알고리즘을 제안한다. 질의 응답을 위해 제안된 기존의 기계 학습 알고리즘들은 답변을 하기 위한 모듈로서 하나의 단어로 이루어진 답변만 할 수 있다는 한계가 있다. 이를 해결하기 위하여 Recurrent Neural Network(RNN)로 단어들의 연속(sequence)으로 이루어진 답변 문장들의 의미를 학습하고, 문장의 의미를 기반으로 질문에 적절한 답변을 찾는 방법을 제안한다. 제안하는 답변 생성 모듈을 최근 제시된 End-to-End Memory Networks(MemN2N)[1] 모델에 적용하여 메모리를 기반으로 스토리를 학습하고, 스토리를 바탕으로 질문에 적절한 답변을 문장 형태로 제시하는 모델을 보인다. 실험을 위하여 5개의 동화의 내용에 대한 질의 응답 데이터 세트를 Amazon Mechanical Turk로 수집하였고, 실제로 대화형태로 질의 응답을 하는 예를 실험 결과로 보인다.

1. 서 론

질의 응답을 위해 최근 제시된 알고리즘인 MemN2N을 확장하여 비디오의 스토리를 학습하고 이에 대하여 대화 형태로 묻고 답하는 알고리즘을 소개한다. 본 논문에서는 시간흐름에 따라 진행되는 일련의 정보에 대해서 물어보는 자연언어형태의 질문을 입력으로 받아 적절한 답변을 찾을 수 있는 기계학습 알고리즘을 제시한다. 질의 응답이라고 불리는 이 문제는 알고리즘이 주어진 정보 및 상황에 대해서 정확히 학습했는지 확인할 수 있기 때문에 기계학습분야에서 중요한 응용분야로 대두되고 있다.

기존 MemN2N에서 활용하는 bAbI 데이터 세트는 완전한 문장의 질문과 단답형으로 구성되어 있다. 하나의 단어는 암시하는 의미가 매우 다양하기 때문에 단답형으로도 중복적으로 여러 질문에 답변을 할 수 있다. 이 점을 이용해 질문에 따른 답변을 높은 정확도로 분류하는 알고리즘이다. 하지만, 실제로 단답형으로는 세부적인 의사를 알 수 없어 완전한 문장을 통해서만 답변이 가능한 경우가 발생한다. 문장은 여러 단어들의 조합으로 무수히 많은 경우의 수가 발생하고 중복성이 낮아 분류기를 통한 답안 도출에 한계가 있다. 이 문제를 해결하기 위해서 질의응답 모델에서는 문장 단위의 처리가 필요하다.

문장은 여러 단어들끼리 문법적 관계를 이루면서

유의미한 내용을 담고 있다. 단어들의 유기적인 관계를 통해 답변을 예측할 수 있도록 문장의 의미를 가지면서 수치적 해석 가능한 표현(representation)을 얻어내야 한다. 기존 MemN2N에서는 모든 단어들의 분류될 가능성을 최종 결과물로 추출하는 반면, 본 논문에서 제안하는 모델은 답변에 해당하는 문장 표현을 예측한다. 본 논문에서는 문장에 대한 표현을 얻기 위해 Skip-Thought Vector(Sent2Vec)[2] 모델을 활용하였다. 예측 값과 기대 답변의 문장 표현 값의 손실을 줄이는 방향으로 학습하는 문장 질의 모델을 제안한다.

2. 질의 응답을 위한 메모리 모델

본 절에서는 문장 형 답변을 생성하기 위한 모듈을 소개한다. 모델의 출력으로서 문장을 표현하는 부호화(encoding) 방법과 그것을 이용하여 모델의 매개변수(parameter)를 학습하기 위해 새롭게 정의한 목적함수를 보인다.

2.1 답변 표현 예측을 위한 확장된 MemN2N

간단한 확장을 통해 기존 MemN2N 모델에서 답변의 표현을 예측하도록 변경할 수 있다. MemN2N 모델은 특정 단어가 답변으로 선택될 확률을 예측한다.[1] 출력으로 기대 답변의 문장 표현과 동일한 차원의 표현

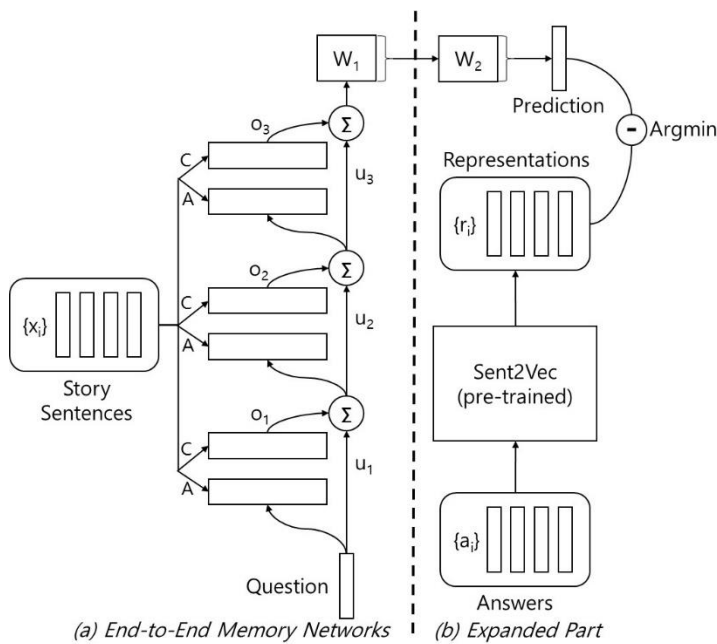


그림 1. 표현 예측을 위한 확장된 MemN2N

(a) End-to-End Memory Networks.[1]

(b) 문장 표현을 추출하여 손실을 정의

벡터를 얻기 위해 기존 모델에서 하나의 완전 연결 은닉 층(fully connected hidden layer)을 확장한다. 그림 1-(b)에서처럼 MemN2N의 출력에 가중치 W_2 를 사상시켜 답변의 문장 표현을 예측하게 된다.

2.2 기대 문장 표현 (Sentence Representation)

문장으로 되어있는 답변을 표현 벡터로 변경해주어야 목적함수에서 학습이 이루어질 수 있다. 감독 학습을 할 때는 기대 값과 예측 값의 오차를 계산하고 기울기에 따라 오차를 줄여가면서 학습을 하게 된다.[3] 이 때 기대 값과 예측 값의 데이터 형태와 크기가 동일해야 적절하게 오차를 계산할 수 있고, 대화형 질의 응답을 위해서는 문장의 의미를 모두 포함하는 표현을 추출할 필요가 있다.

먼저, 문장의 단어들끼리 의미적인 상관관계를 유지하면서 수치로 표현하기 위해서 Word2Vec[4]을 이용해 단어들을 벡터로 표현한다. 단어 벡터들로 이루어진 문장 행렬은 Gated Recurrent Unit(GRU)[5]를 이용해 비슷한 의미의 문장은 유사한 벡터를 가질 수 있는 유의미한 문장 벡터를 추출할 수 있다. 위의 일련의 과정을 수행하는 모델인 Sent2Vec을 활용하여 문장 표현을 얻을 수 있었다. 이 모델은 비슷한 의미의 문장들끼리 유사한 벡터를 가질 수 있게 해준다.[2]

2.3 목적함수 정의

전체적인 모델은 그림 1에서 보는 바와 같이 기존 MemN2N에서 확장하여 문장 표현 부분과 기대 답변의 표현을 추출하는 부분을 설계하였다.

일반적인 분류 문제와 동일하게 예측한 값과 기대 값의 오차를 계산하여 학습한다. 테스트 데이터를 이용해 답변을 예측을 하려면 그림 1과 같이 확장된 MemN2N의 출력 값과 미리 학습된 Sent2Vec를 통해 추출된 기대 표현 벡터들 중에 오류가 가장 적은 벡터를 선택하고 선택된 벡터에 해당하는 원래 문장을 예측 답변으로 선정한다.

3. 실험

3.1 실험 설정 및 데이터

제안된 모델이 학습이 잘 진행되고 있는지 확인하기 위해 학습함에 따라 손실이 줄어 들고, 출력물의 정확도가 향상되며, 예측된 결과와 기대하는 결과가 의미적으로 비슷한 내용을 담고 있는지 확인하는 실험을 했다.

실험을 위한 데이터로 스마트 스터디[6]의 5개 동화, ‘헨젤과 그레텔’, ‘백설공주’, ‘인어공주’, ‘늑대와 일곱 마리 아기염소’ ‘아기돼지 삼형제’를 사용하였다. 동영상으로 구성된 전래동화 동영상에서 영어자막을 추출하여 모델학습에 사용하였고, 이야기를 바탕으로 Amazon Mechanical Turk에서 질문과 대답 데이터를 수집하였다. 평균 55문장의 동화 줄거리와 이야기에 대한 질문 및 답변을 한 세트로 동화당 각 600개 내외의 질의 응답 데이터 세트를 시험에 사용했다.

목적함수의 손실 계산은 예측된 벡터 값이 음수가 나올 수 있기 때문에 cross-entropy를 제외한 1-norm와 2-norm 두 가지 방법으로 비교해 보았다. 해당 모델의 예측 수행 정확도를 확인하기 위한 척도로써 기대 문장과 예측 문장 사이의 유사성을 측정해 주는 BLEU Score[7]를 사용하였다.




그림 2. 학습 량에 따른 손실 값과
검증 데이터의 정확도

표 1. 데이터 별 BLEU Score

동화 제목	손실 계산 방법 (학습률=0.005)		학습률 (손실계산=2-norm)			
	1-norm	2-norm	0.001	0.002	0.005	0.01
헨젤과 그레텔	0.336	0.371	0.336	0.368	0.371	0.361
백설공주	0.366	0.430	0.389	0.405	0.430	0.445
인어공주	0.418	0.449	0.456	0.429	0.449	0.439
아기돼지 삼형제	0.339	0.392	0.361	0.343	0.392	0.411
늑대와 일곱염소	0.320	0.354	0.340	0.342	0.354	0.365
평균	0.356	0.399	0.376	0.377	0.399	0.404

표 2. 질의 응답 결과 문장 예시

이야기	헨젤과 그레텔	백설공주
질문	who wanted the kids to be left in the forest	what does hansel drop on the ground
기대 답변	the stepmother.	stones.
예측 답변	the stepmother took them to the forest.	hansel drops shiny stones on the way to the forest.
이야기	인어공주	아기돼지 삼형제
질문	where did the little mermaid live	what was the house of middie made of
기대 답변	in the sea.	wood.
예측 답변	deep inside the sea.	middie builds the house with wood.

3.2 실험 결과

실험은 학습함에 따라 손실 총량과 최종결과의 정확도가 수렴하는 것을 그래프를 그려 확인했다. 학습 데이터에서의 손실 값과 검증 데이터에서의 정확도가 잘 수렴하고 있음을 그림 2를 통해 알 수 있다.

제안된 모델의 정확도를 높이기 위해 손실 계산 방법 선택과 학습률(learning rate) 미세조정(fine-tuning)을 하였다. 표 1은 데이터 별로 학습 방법과 수치를 변경하면서 테스트한 BLEU Score를 나타낸다. 동화 별로 가장 잘나온 방법은 다르지만, 평균적으로 봤을 때 2-norm를 이용해 손실을 계산하고 학습률 '0.01'를 사용했을 때 가장 정확한 결과가 나오는 것을 확인할 수 있다.

기대 답변보다 예측 답변이 의미상으로 더 잘 표현됐을 수 있어 육안으로 확인했고, 의미적으로 더 잘 통하는 답변이 존재함을 확인했다. 표 2에서 보는 바와 같이 의미상으로 더 나은 답변을 예측한 경우에도 BLEU Score 결과가 낮게 나올 수 있어 표 1에서 BLEU Score 결과가 낮게 나온 이유를 유추해 볼 수 있다.

동화 당 600개 세트의 적은 학습 데이터로도 만족할

수 있는 수준의 결과를 얻을 수 있었던 실험이었다. BLEU Score가 수치적으로는 높지 않을 수 있으나, 데이터 수가 적었던 점과 제대로 도출된 결과로도 정확도가 낮게 계산될 수 있다는 점을 감안하면 의미 있는 실험 결과를 얻었다고 볼 수 있다.

4. 결 론

제안된 모델을 이용하면 문장으로 구성된 답변을 예측하는 데에 효과적으로 학습할 수 있음을 확인할 수 있었다. 비록 학습에 사용된 데이터의 수가 적었지만 유의미한 수준의 결과를 얻어내었고, 많은 데이터로는 더 정확한 결과를 얻을 수 있을 것으로 기대한다.

처음 의도했던 연구 목표는 미리 학습된 Sent2Vec을 사용하여 답변의 표현을 추출했던 방식이 아닌 학습되지 않은 Sent2Vec을 이용해 양방향으로 학습시키는 것이었다. 하지만 고정되어 있지 않은 기대 값이 학습 목표가 명확하지 않아, 결국 학습결과가 수렴하지 않고 실패하였다. 앞으로, 더 완전한 대화형 질의 모델 학습을 위해서 미리 학습된 모델 없이 동적으로 학습 가능한 모델 연구와 대화하면서 스스로 학습할 수 있는 점진적인 메모리 신경망에 대한 연구를 진행할 계획이다.

감사의 글

이 논문은 2016년도 정부(미래창조과학부, 국방부)의 재원으로 정보통신기술진흥센터(R0126-16-1072-SW스타랩), 한국산업기술평가관리원(10044009-HRI.MESSI, 10060086-RIS F), 국방과학연구소(UD130070ID-BMRR)의 지원을 받았음.

참 고 문 헌

- [1] Sainbayar Sukhbaatar, Arthur Szlam, Jason Weston, and Rob Fergus. End-To-End Memory Networks. NIPS. 2015
- [2] Ryan Kiros, Yukun Zhu, Ruslan Salakhutdinov, Richard S. Zemel, Antonio Torralba, Raquel Urtasun, Sanja Fidler. Skip-Thought Vectors. NIPS. 2015.
- [3] David E. Rumelheart, Geoffrey E. Hinton and Ronald J. Williams. Learning representations by back-propagating errors. Nature, 323(6088), 1986.
- [4] Tomas Mikolov, Ilya Sutskever, Kai Chen, Greg Corrado, and Jeffrey Dean. Distributed Representations of Words and Phrases and their Compositionality. NIPS. 2013.
- [5] Kyunghyun Cho, Bart van Merriënboer, and Dzmitry Bahdanau. On the Properties of Neural Machine Translation: Encoder-Decoder Approaches. SSST-8, 2014.
- [6] Smart Study Pinkfong, [Online]. Available web-site: <https://about.pinkfong.com/en/about>
- [7] Kishore Papineni, Salim Roukos, Todd Ward, and Wei-Jing Zhu. Bleu: a method for automatic evaluation of machine translation. In ALC, 2002.